

1. Span

$$v_8 = \sum_{i=1}^7 \alpha_i v_i \Rightarrow v_8 \in \text{Span}\{v_1, \dots, v_7\}$$

$v_8 - \sum_{i=1}^7 \alpha_i v_i = 0$ 若有解，则也 span.

2. Inner Product (Dot product)

$$\langle u, v \rangle = u \cdot v = \sum_{i=1}^n u_i \cdot v_i \quad \|u\|_2 = \sqrt{\sum_{i=1}^n u_i^2} = \sqrt{u \cdot u} = \text{the vector's length}$$

$$|u \cdot v| \leq \|u\|_2 \cdot \|v\|_2$$

3. Orthogonal & Orthonormal

两个向量 u 和 v 被称为正交，当且仅当它们的内积为零：

$$u \cdot v = 0$$

标准正交 (Orthonormal)

如果两个向量不仅正交（即 $u \cdot v = 0$ ），而且它们的长度（范数）为 1，则称它们为标准正交：

几何解释：

$$\|u\| = \|v\| = 1$$

1. 正交意味着这两个向量在几何上是垂直的（夹角 $\theta = 90^\circ$ ）。

几何解释：

2. 这是因为内积公式：

$$u \cdot v = \|u\| \|v\| \cos \theta$$

当 $\cos \theta = 0$ 时， $\theta = 90^\circ$ ，即向量相互垂直。

1. 标准正交表示两个向量不仅彼此垂直，而且是单位向量（长度为 1）。

4. Basis

basis is the minimal representation of subspace (all vectors are linearly independent and every other vector in the subspace can be represented as a linear combination of the basis vectors). A basis is orthonormal if and only if all the vectors in the basis are orthogonal to each other and have a length of 1.

A basis $B = \{v_1, v_2, \dots, v_m\}$ for a subspace $V \subset \mathbb{R}^n$ is called **orthonormal** if:

$$\langle v_i, v_j \rangle = \begin{cases} 1 & \text{if } i = j \\ 0 & \text{if } i \neq j \end{cases}$$

We can define a vector $u \in V$, where V has an orthonormal basis of $\{v_1, v_2, \dots, v_m\}$. Since we know u is a linear combination of the vectors in the basis, we can write u as

$$u = \sum_{i=1}^m \alpha_i v_i \quad \text{where } \alpha_i \in \mathbb{R}$$

To find these α values, we can simply take the dot product of u with each vector in the orthonormal basis v_i .

$$\begin{aligned} \langle u, v_j \rangle &= \left\langle \sum_{i=1}^m \alpha_i v_i, v_j \right\rangle \\ &= \sum_{i=1}^m \alpha_i \langle v_i, v_j \rangle \\ &= \alpha_j \end{aligned}$$

We can also define this dot product of u and v_j as the length of the projection of u onto v_j .

We can then continue to further prove that the 2-norm (length) of a vector is simply the sum of these α_i values squared. Specifically, that

$$\sum_{i=1}^m \alpha_i^2 = \|u\|_2^2$$

5. Projection

10.1.1 Projection Formula

The projection of a vector $u \in \mathbb{R}^n$ onto a vector v_j is given by:

$$\text{proj}(u, v_j) = \frac{\langle u, v_j \rangle}{\langle v_j, v_j \rangle} v_j$$

If W is the subspace spanned by orthonormal vectors v_1, \dots, v_k , then the projection of u onto W is:

$$\text{proj}(u, W) = \sum_{i=1}^k \langle u, v_i \rangle v_i$$

Consider a vector $v = (2, 1, 2)$ and the xy-plane spanned by $(1, 0, 0)$ and $(0, 1, 0)$. The projection of v onto the xy-plane is:

$$\text{proj}(v, \text{xy-plane}) = \langle v, (1, 0, 0) \rangle \cdot (1, 0, 0) + \langle v, (0, 1, 0) \rangle \cdot (0, 1, 0) = (2, 1, 0)$$

6. Gram-Schmidt Algorithm

Given vectors v_1, v_2, \dots, v_m in \mathbb{R}^n that form a basis for a subspace V , the Gram-Schmidt process outputs orthonormal vectors u_1, u_2, \dots, u_m that span the same subspace V as follows:

$$u_1 = \frac{v_1}{\|v_1\|}$$

Given vectors v_1, \dots, v_8 in \mathbb{R}^n , we want to address the following questions:

- Q: Is v_8 in the span of v_1, \dots, v_7 ?

We want to minimize:

$$\min \|v_8 - w\| \quad \text{where } w \in \text{span}(v_1, \dots, v_7)$$

To solve this, we will use **Gram-Schmidt Orthogonalization** to construct an orthonormal basis u_1, \dots, u_7 . The projection of v_8 onto the subspace spanned by u_1, \dots, u_7 will give us the vector w that minimizes the distance, with our notion of "distance" defined as the 2-norm.

通过正交基的性质，投影可以直接用公式计算：

$$w = \sum_{i=1}^7 \langle v_8, u_i \rangle u_i \quad \longrightarrow \quad w = \sum_{i=1}^k \beta_i w_i, \quad \beta_i = \langle v_8, w_i \rangle.$$

Error: $\sum_{i=1}^n (v_i - w_i)^2$

7. Eigenvalue & Eigenvector

Suppose $A \in \mathbb{R}^{n \times n}$, then $x \in \mathbb{R}^n$ and $\lambda \in \mathbb{R}$ is said to be an eigenvector-eigenvalue pair if:

$$Ax = \lambda x$$

Find eigenvalues:

$$M_\lambda = A - \lambda I$$

$$\det(M_\lambda) = 0 \Rightarrow \sum_{i=1}^n \alpha_i v_i = 0$$

这也意味着 M_λ is noninvertible

The eigenvector v corresponding to an eigenvalue must be non-zero by definition.

8. Invertible

一个矩阵 A 是可逆矩阵 (invertible matrix 或 nonsingular matrix)，如果存在另一个矩阵 A^{-1} (称为 A 的逆矩阵)，满足以下两个条件：

$$A \cdot A^{-1} = I \quad \text{和} \quad A^{-1} \cdot A = I$$

其中， I 是单位矩阵 (identity matrix)，其对角线元素全为 1，其他元素全为 0。

1. 矩阵可逆的核心思想：

一个矩阵 A 可逆，意味着我们可以“还原”它的线性变换——对于任何向量 v ，如果知道 Av ，就可以用 A^{-1} 找回 v 。

例如：如果 $Av = b$ ，我们可以通过 $v = A^{-1}b$ 找回 v 。

2. 可逆矩阵是全秩矩阵：

如果 A 是 $n \times n$ 方阵，它的行和列必须是线性无关的 (即满秩, rank = n)，才能可逆。

3. 行列式的作用：

一个 $n \times n$ 方阵 A 的行列式 (determinant) 可以判断它是否可逆：

- 如果 $\det(A) \neq 0$ ，则 A 可逆。
- 如果 $\det(A) = 0$ ，则 A 不可逆 (也称为奇异矩阵, singular matrix)。

ex: $\begin{bmatrix} 1 & 0 & 0 \\ 0 & -5 & 0 \\ 0 & 0 & 7 \end{bmatrix} = 1 \cdot \begin{bmatrix} 1 \end{bmatrix} [1 \ 0 \ 0] - 5 \cdot \begin{bmatrix} 0 \\ 1 \end{bmatrix} [0 \ 1 \ 0] \dots$

$$A^2 = \sum_{i,j=1}^n \lambda_i \lambda_j (v_i(v_i^T v_j)v_j^T) = \sum_{i=1}^n \lambda_i^2 v_i v_i^T$$

9. Special theorem for symmetric matrix

If $A \in \mathbb{R}^{n \times n}$ is symmetric, then all eigenvalues are real.

Further, A can be expressed as:

$$A = \sum_{i=1}^n \lambda_i v_i v_i^T \quad (\text{Spectral decomposition})$$

where v_1, \dots, v_n are orthonormal unit vectors, and:

$$\langle v_i, v_j \rangle = \begin{cases} 1 & i=j \\ 0 & i \neq j \end{cases} \quad Av_i = \lambda_i v_i \quad \forall 1 \leq i \leq n$$

假设 $\|x\|_2 = x^T x = \sum_{i=1}^n \alpha_i^2 = 1$
则 $R = x^T A x = (\sum_{i=1}^n \alpha_i v_i)^T A (\sum_{j=1}^n \alpha_j v_j)$
 $= \sum_{i=1}^n \lambda_i \alpha_i^2$

注: x 可以被写成 $\sum_{i=1}^n \alpha_i v_i$

5. 优化问题

目标：找到一个单位向量 x 使得 $x^T A x$ 最大化。

利用 Rayleigh 公式：

$$R(x) = \sum_{i=1}^n \lambda_i \alpha_i^2$$

• 由于 $\alpha_i^2 \geq 0$ 且 $\sum_{i=1}^n \alpha_i^2 = 1$ ， $R(x)$ 的值由最大的特征值 λ_{\max} 主导。

• 为了最大化 $R(x)$ ，需要让 $\alpha_1^2 = 1$ ，即 x 完全沿最大特征值 λ_{\max} 的特征向量方向 v_1 排布。

解：最优 x 是 v_1 (最大特征值的特征向量)。

The expression $\sum_{i=1}^n \alpha_i^2 \lambda_i$ is maximized when $\alpha_1 = 1$ and $\alpha_2 = \alpha_3 = \dots = \alpha_n = 0$. This implies that we are allotting our entire budget (recall that $\sum_{i=1}^n \alpha_i = 1$) to our largest eigenvalue λ_1 , and in doing so, we make $x = v_1$.

$$R(y) = \frac{y^T A y}{y^T y} = \frac{(cx)^T A (cx)}{(cx)^T (cx)} = \frac{c^2 x^T A x}{c^2 x^T x} = R(x)$$

因此，Rayleigh 商只依赖于 x 的方向，而与其大小无关。

性质

- 缩放不变性：Rayleigh 商对 x 的缩放不敏感。如果 $y = cx$ ($c \neq 0$ 是标量)，则：

$$R(y) = \frac{y^T A y}{y^T y} = \frac{(cx)^T A (cx)}{(cx)^T (cx)} = \frac{c^2 x^T A x}{c^2 x^T x} = R(x)$$

11. Variational Characteristic of Eigenvalues

Now, suppose we add an additional constraint to our optimization problem. 3. 递归优化与一般性结果

$$\begin{aligned} \max & \quad x^T A x \\ \text{s.t.} & \quad x^T x = 1 \\ & \quad \langle x, v_1 \rangle = 0 \end{aligned}$$

通过类似的步骤, 可以递归地限制 x 正交于之前的特征向量 v_1, v_2, \dots, v_{k-1} , 从而找到下一个最大的特征值 λ_k 和对应特征向量 v_k 。总结如下:

- 最大特征值: $\lambda_1 = \max_x x^T A x$, where $x = v_1$.
- 第二大特征值: $\lambda_2 = \max_{x \perp v_1} x^T A x$, where $x = v_2$.
- 一般情形: $\lambda_k = \max_{x \perp \{v_1, v_2, \dots, v_{k-1}\}} x^T A x$, where $x = v_k$.

12. Singular Value Decomposition (SVD)

1. 什么是奇异值分解?

假设我们有一个矩阵 $A \in \mathbb{R}^{m \times n}$, 其中 $n \geq m$ 。奇异值分解 (SVD) 将矩阵 A 分解为以下形式:

$$A = \sum_{i=1}^m \sigma_i u_i v_i^T,$$

where each term $\sigma_i u_i v_i^T$ is a rank-1 matrix, $u_i \in \mathbb{R}^m$, and $v_i \in \mathbb{R}^n$. Furthermore, the vectors u_1, \dots, u_m are orthonormal, as are v_1, \dots, v_m , and $\sigma_i \geq 0$.

$$\begin{aligned} AA^T &= \left(\sum_{i=1}^m \sigma_i u_i v_i^T \right) \left(\sum_{j=1}^m \sigma_j v_j u_j^T \right) \\ &= \sum_{i=1}^m \sum_{j=1}^m \sigma_i \sigma_j u_i v_i^T v_j u_j^T \\ &= \sum_{i=1}^m \sigma_i^2 u_i u_i^T \end{aligned}$$

since $v_i^T v_j = \begin{cases} 1 & \text{if } i=j \\ 0 & \text{otherwise} \end{cases}$

$$A^T A = \sum_{i=1}^m \sigma_i^2 v_i v_i^T$$

v_1, \dots, v_m are eigenvectors; $\sigma_1^2, \dots, \sigma_m^2$ are eigenvalues.

Step 1: Singular Value Decomposition (SVD) and the Representation of A

1. Definition of SVD: A matrix $A \in \mathbb{R}^{m \times n}$ can be written as:

$$A = U \Sigma V^T$$

where:

- $U = [u_1, u_2, \dots, u_m] \in \mathbb{R}^{m \times m}$ contains orthonormal left singular vectors,
- $V = [v_1, v_2, \dots, v_n] \in \mathbb{R}^{n \times n}$ contains orthonormal right singular vectors,
- $\Sigma \in \mathbb{R}^{m \times n}$ is a diagonal matrix with singular values $\sigma_1, \sigma_2, \dots$ on the diagonal.

2. SVD in Summation Form: Using the above, A can be expressed as:

$$A = \sum_i \sigma_i u_i v_i^T$$

Substitute these orthogonality conditions back into the expression:

$$\|A\|_F^2 = \sum_{j,k} \sum_{i,\ell} \sigma_i \sigma_\ell \delta_{i\ell} \delta_{i\ell} = \sum_i \sigma_i^2$$

Thus:

$$\|A\|_F^2 = \sum_i \sigma_i^2$$

13. Direction of Maximum Variance

我们希望找到一个单位向量 x (即 $\|x\|_2 = 1$), 使得 $\|Ax\|_2$ 最大化。

这个问题可以写成:

$$\max_{\|x\|_2=1} \|Ax\|_2,$$

或者等价地写成:

$$\max_{x \neq 0} \frac{\|Ax\|_2}{\|x\|_2}.$$

而 $\|Ax\|_2^2 = \langle Ax, Ax \rangle$ 和 $\|x\|_2^2 = \langle x, x \rangle$, 因此问题变为:

$$\max_{x \neq 0} \sqrt{\frac{\langle Ax, Ax \rangle}{\langle x, x \rangle}}.$$

简化问题

进一步简化, 可以写成:

$$\max_{x \neq 0} \sqrt{\frac{(Ax)^T (Ax)}{x^T x}}.$$

再简化为:

$$\max_{x \neq 0} \sqrt{\frac{x^T (A^T A) x}{x^T x}}.$$

到这里, 我们可以将问题归约为:

$$\max_{x \neq 0} \frac{x^T (A^T A) x}{x^T x}.$$

这个形式与 Rayleigh 商相同, 最大值等于 $A^T A$ 的最大特征值。

so:

$$\|A\|_F^2 = \sum_{j,k} \left(\sum_i \sigma_i (u_i)_j (v_i)_k \right)^2$$

(b) Expanding the Square

Expand the square:

$$\|A\|_F^2 = \sum_{j,k} \sum_{i,\ell} \sigma_i \sigma_\ell (u_i)_j (v_i)_k (u_\ell)_j (v_\ell)_k$$

(c) Orthogonality of u_i and v_i

- The vectors u_i are orthonormal, so:

$$\sum_j (u_i)_j (u_\ell)_j = \delta_{i\ell}$$

where $\delta_{i\ell}$ is the Kronecker delta (1 if $i = \ell$, 0 otherwise).

- Similarly, the vectors v_i are orthonormal, so:

$$\sum_k (v_i)_k (v_\ell)_k = \delta_{i\ell}$$

(arranged in decreasing order of σ_i 's), where:

- $\sigma_1, \dots, \sigma_m$ are the singular values, which are non-negative real numbers ($\sigma_i \geq 0$).
- u_1, \dots, u_m are orthonormal unit vectors in \mathbb{R}^m .
- v_1, \dots, v_n are orthonormal unit vectors in \mathbb{R}^n , forming the right singular vectors.

特征值与奇异值的关系

在 SVD 中, $A^T A$ 的特征值是奇异值的平方:

$$\lambda_1 = \sigma_1^2, \quad \lambda_2 = \sigma_2^2, \dots$$

因此, $A^T A$ 的最大特征值是 σ_1^2 , 对应的特征向量是 v_1 。于是:

$$\max_{x \neq 0} \frac{x^T (A^T A) x}{x^T x} = \sigma_1^2.$$

方向与最大奇异值

为了达到这个最大值, 单位向量 x 必须是 $A^T A$ 的主特征向量 v_1 。因此:

$$\max_{\|x\|_2=1} \|Ax\|_2 = \sigma_1, \quad \text{where } x = v_1.$$

(1) Rayleigh 商定理 Rayleigh 补充

Rayleigh 商定理指出:

1. 对于对称矩阵 $A^T A$, Rayleigh 商 $R(x) = \frac{x^T (A^T A) x}{x^T x}$ 的最大值等于 $A^T A$ 的最大特征值。
2. 最大值对应的 x 是矩阵 $A^T A$ 的主特征向量 (即对应最大特征值的特征向量)。

因此:

$$\max_{x \neq 0} \frac{x^T (A^T A) x}{x^T x} = \lambda_1,$$

其中 λ_1 是 $A^T A$ 的最大特征值。

(2) 奇异值与特征值的关系

在奇异值分解 (SVD) 中:

- $A^T A$ 的特征值是奇异值的平方:

$$\lambda_i = \sigma_i^2.$$

- σ_1 是矩阵 A 的最大奇异值, 因此 $\lambda_1 = \sigma_1^2$ 。

Similarly to Sec. 12.3, we can find the next largest singular value by maximizing $\|Ax\|_2$ when x is orthogonal to the previous singular vectors. Define σ_1 as:

$$\sigma_1 = \max_{x \neq 0} \frac{\|Ax\|_2}{\|x\|_2}.$$

Now suppose $\langle x, v_1 \rangle = 0$ and let $x = \sum_{j=2}^n \alpha_j v_j$. Then,

$$\begin{aligned} Ax &= \left(\sum_{i=1}^n \sigma_i u_i v_i^T \right) \left(\sum_{j=2}^n \alpha_j v_j \right) \\ &= \sum_{j=2}^m \alpha_j \sigma_j u_j. \end{aligned}$$

To maximize $\|Ax\|_2$, set $\alpha_2 = 1$. Then the maximum value becomes σ_2 when $x = v_2$, and so on...

Therefore,

$$\beta_1 = 1, \beta_2 = \beta_3 = \dots = \beta_m = 0$$

$$\|Ax\|_2 = \sigma_1$$

Hence,

$$\sigma_1 = \max_{x: \|x\|_2=1} \|Ax\|_2 ; \quad v_1 = \arg \max_{x: \|x\|_2=1} \|Ax\|_2$$

Similarly,

$$\begin{aligned} \sigma_2 &= \max_{x: \|x\|_2=1, \langle x, v_1 \rangle = 0} \|Ax\|_2 ; \quad v_2 = \arg \max_{x: \|x\|_2=1, \langle x, v_1 \rangle = 0} \|Ax\|_2 \\ \sigma_k &= \max_{x: \|x\|_2=1, \langle x, v_1 \rangle = \dots = \langle x, v_{k-1} \rangle = 0} \|Ax\|_2 ; \quad v_k = \arg \max_{x: \|x\|_2=1, \langle x, v_1 \rangle = \dots = \langle x, v_{k-1} \rangle = 0} \|Ax\|_2 \end{aligned}$$

14. SVD 的奇怪定理

Given matrix A , the matrix A_k of rank- k which minimizes both the 2-norm and Frobenius norm is given by

$$A_k = \sum_{i=1}^k \sigma_i u_i v_i^T$$

where

$$A = \sum_{i=1}^m \sigma_i u_i v_i^T$$

给定矩阵 A 的奇异值分解 (Singular Value Decomposition, SVD), 存在一个秩为 k 的矩阵 A_k , 它是以下两个范数意义上的最佳近似:

1. 2-范数 (Spectral Norm): 最大奇异值对应的近似误差最小;
2. Frobenius 范数: 所有元素的平方和的近似误差最小。

If A, B belong to the same cluster, then:

$$\varepsilon_c = \begin{cases} 1 & \text{if both } (A, C), (B, C) \text{ are present/absent} \\ 0 & \text{otherwise} \end{cases}$$

$$E \left[\sum_c \varepsilon_c \right] \geq 0.81 \cdot (n - 2)$$

$$\Pr \left(\sum_c \varepsilon_c \leq \frac{n-2}{2} \right) \leq \Pr \left[\left| \sum_c \varepsilon_c - E \left(\sum_c \varepsilon_c \right) \right| \geq 0.31 \cdot (n-2) \right]$$

$$\leq e^{-\frac{(0.31)^2 \cdot (n-2)^2}{4 \cdot (n-2)}} \approx e^{-0.02n}$$

$$= \Pr \left(\sum_c \varepsilon_c \geq \frac{n-2}{2} \right) \geq 1 - e^{-0.02n}$$

If A, B belong to different clusters:

$$E \left[\sum_c \varepsilon_c \right] \leq 0.18 \cdot (n - 2)$$

$$\Rightarrow \Pr \left(\sum_c \varepsilon_c \geq \frac{(n-2)}{2} \right) \leq e^{-0.02 \cdot n}$$

As long as:

$$\frac{n(p-q)}{2} \gg \sqrt{n(p+q)},$$

which simplifies to:

$$\frac{p-q}{2} \gg \frac{1}{\sqrt{n}},$$

we can successfully recover the communities using the spectral method described above.

Chernoff Bound:
If x_1, x_2, \dots, x_n are random variables in $[-1, 1]$, then $\Pr[(\sum_i x_i - \mathbb{E}[\sum_i x_i]) \geq t] \leq e^{-\frac{t^2}{4n}}$

We aim to recover the partition (S, \bar{S}) when:

$$p \geq q + \frac{\log 5n}{\sqrt{n}}.$$

Fact 1: The all-ones matrix $J_{n/2}$ of size $n/2 \times n/2$ has exactly one non-zero eigenvalue $\lambda = n/2$, with corresponding eigenvector $\mathbf{v} = \frac{1}{\sqrt{n/2}} \mathbf{1}$, where $\mathbf{1}$ is the vector of all ones. All other eigenvalues are zero.

Fact 2: If a matrix B has eigenvector v with eigenvalue λ , then for any scalar c , the matrix $B - cI$ has eigenvector v with eigenvalue $\lambda - c$.

16. Random Matrix Analysis

1. 随机矩阵 Δ 的定义:

$$\Delta = C - C' = M - A.$$

矩阵 Δ 捕捉了随机噪声的特性。

- 每个元素 Δ_{ij} 是随机的, 但独立 (对称性除外)。
- 期望 $\mathbb{E}[\Delta_{ij}] = 0$ 。
- 方差 $\text{Var}(\Delta_{ij})$:

$$\text{Var}(\Delta_{ij}) = \begin{cases} p(1-p), & \text{如果 } i \neq j \text{ 且在同一社区,} \\ q(1-q), & \text{如果 } i \neq j \text{ 且在不同社区.} \end{cases}$$

2. 矩阵分析工具:

Tao-Vu 定理:

如果矩阵 Δ 是对称的随机矩阵, 且方差 σ^2 满足某些条件 (例如 $\sigma^2 \leq \frac{\log^4 n}{n}$) , 则最大奇异值 Δ 至少为 $2\sigma\sqrt{n}$ 。

Davis-Kahan 定理:

假设两个对称矩阵 M 和 M' 有不同的特征值和特征向量。如果 $\Delta = M - M'$, 则奇异值的界限可以控制特征向量的偏差。

$$\text{Var}(\Delta_{ij}) = \begin{cases} p(1-p), & \text{if } i = j, \\ p(1-p), & \text{if } i \neq j \text{ and } (i,j) \text{ in same community,} \\ q(1-q), & \text{if } i \neq j \text{ and } (i,j) \text{ in different communities.} \end{cases}$$

Note that $p(1-p), q(1-q) \leq p+q$.

意义: 这些定理帮助我们量化噪声 (随机矩阵) 对特征向量的影响。

17. d -regular graph & Laplacian matrix (L_G)

1. d -正则图 G :

- 一个无向图，其中每个顶点都有 d 个邻居（度数为 d ）。
- 邻接矩阵 A_G 的定义：

$$A_G(i, j) = \begin{cases} 1, & \text{如果 } (i, j) \in E, \\ 0, & \text{否则.} \end{cases}$$

2. Laplacian 矩阵 L_G : 定义为：

$$L_G(i, j) = \begin{cases} d, & \text{如果 } i = j, \\ -1, & \text{如果 } (i, j) \in E, \\ 0, & \text{否则.} \end{cases}$$

其中：

- 对角线元素是节点的度数 d ；
- 非对角线元素是边的存在性（负值）。

3. 性质：

- L_G 是对称矩阵。
- 所有特征值都是非负的（重要结论）。

直观解释

- 对角元素 L_{ii} : 表示顶点 i 的度数（与该顶点相连的边的条数）。
- 非对角元素 L_{ij} : 如果 i 和 j 有边相连，值为 -1 ；如果无边相连，值为 0 。
- 性质：拉普拉斯矩阵是对称的（对无向图）且半正定。

重要性质

1. 特征值性质：

- 拉普拉斯矩阵的特征值非负。
- 最小特征值总是 0 ，对应特征向量是全 1 向量。
- 图的连通性和拉普拉斯矩阵的第二小特征值（称为代数连通度）密切相关。

2. 矩阵的行和为零：

- L 的每一行的元素和为 0 。

矩阵形式：

$$L_{ij} = \begin{cases} \text{度数 } (\deg(i)), & \text{如果 } i = j \\ -1, & \text{如果 } i \neq j \text{ 且 } (i, j) \in E \\ 0, & \text{如果 } i \neq j \text{ 且 } (i, j) \notin E \end{cases}$$

示例：一个简单的图

假设 G 是一个有 4 个顶点的图，边集为 $E = \{(1, 2), (2, 3), (3, 4), (4, 1)\}$ 。这是一个四边形。

1. 邻接矩阵 A :

$$A = \begin{bmatrix} 0 & 1 & 0 & 1 \\ 1 & 0 & 1 & 0 \\ 0 & 1 & 0 & 1 \\ 1 & 0 & 1 & 0 \end{bmatrix}$$

2. 度矩阵 D :

$$D = \begin{bmatrix} 2 & 0 & 0 & 0 \\ 0 & 2 & 0 & 0 \\ 0 & 0 & 2 & 0 \\ 0 & 0 & 0 & 2 \end{bmatrix}$$

3. 拉普拉斯矩阵 $L = D - A$:

$$L = \begin{bmatrix} 2 & -1 & 0 & -1 \\ -1 & 2 & -1 & 0 \\ 0 & -1 & 2 & -1 \\ -1 & 0 & -1 & 2 \end{bmatrix}$$

L : symmetric & PSD $\rightarrow x^T L x \geq 0$

$L v = \lambda v$

L_G 是 PSD \rightarrow all eigenvalues of $L_G \geq 0$.

性质 1: L_G 是 PSD 矩阵（半正定矩阵）。

证明：

- 考虑任意向量 x , 定义 $x^T L_G x$:

$$x^T L_G x = \sum_{e \in E} L_e x,$$

其中 L_e 是与边 $e = (u, v)$ 相关的拉普拉斯矩阵的贡献。

- 展开后发现：

$$x^T L_G x = \sum_{e=(u,v) \in E} (x_u - x_v)^2,$$

这是平方和，显然非负。

- 因此, L_G 是半正定的，所有特征值都是非负的。

性质 2: L_G 的所有特征值非负:

$$0 = \lambda_1 \leq \lambda_2 \leq \dots \leq \lambda_n.$$

性质 3: $\lambda_1 = 0$, 对应的特征向量是 1 。

- 当 $x = 1$ 时, $x^T L_G x = 0$, 因此 0 是 L_G 的特征值。
- 对应的特征向量是 1 (即每个元素都为 1 的向量)。

性质 4: $\lambda_2 = 0$ 的条件表示图是非连通的。

- 若图 G 是非连通的，可以将其划分为两个不相交的子集 S 和 \bar{S} ，且 x 定义为：

$$x_n = \begin{cases} \frac{1}{|S|}, & \text{如果 } u \in S, \\ -\frac{1}{|\bar{S}|}, & \text{如果 } u \in \bar{S}. \end{cases}$$

则对于任意边 $e = (u, v)$, $x_u = x_v$, 从而 $x^T L_G x = 0$ 。

- 这表明存在另一个特征值 0 (除了 λ_1)，因此 $\lambda_2 = 0$ 。

性质 5: $\lambda_2 > 0$ 表示图是连通的。

- 如果 $\lambda_2 > 0$, 则图是连通的，没有额外的特征向量对应于特征值 0 。

Fact 2: If eigenvalues of L_G are $\lambda_1 \leq \dots \leq \lambda_n$ then, $\lambda_1 = 0$. $\lambda_2 = 0$ iff G is disconnected.

- 最大特征值 λ_n 可以通过一个二次型的形式表示：

$$\lambda_n = \max_{x \neq 0} \frac{x^T L_G x}{x^T x} = \max_{x: \|x\|_2=1} x^T L_G x$$

18. Positive Semi-definite (PSD)

1. PSD 矩阵的定义

一个 $n \times n$ 的对称矩阵 A 被称为 PSD 矩阵，如果对于任意非零向量 $x \in \mathbb{R}^n$, 满足以下条件：

$$x^T A x \geq 0.$$

如果严格满足 $x^T A x > 0$ (对所有 $x \neq 0$)，则称为 正定矩阵 (Positive Definite Matrix, PD 矩阵)。

2. PSD 矩阵的关键性质

- 对称性: PSD 矩阵必须是对称矩阵 (即 $A = A^T$)。
- 特征值非负: PSD 矩阵的所有特征值 λ 都是非负的 (即 $\lambda \geq 0$)。
- 二次型非负: 对任意向量 x , 二次型 $x^T A x \geq 0$ 。

19.

$$x^\top L_G x = x^\top \left(\sum_e L_e \right) x = \sum_e x^\top L_e x = \sum_{e=(u,v)} (x_u - x_v)^2$$

You can go over all the edges of the graph and look at the Laplacian for the edges but the edge Laplacian is this matrix:

$$L_e(i,j) = \begin{cases} 1 & \text{if } i=j=u \text{ or } i=j=v \\ -1 & \text{if } i=u, j=v \text{ or } i=v, j=u \\ 0 & \text{otherwise} \end{cases}$$

$$x^\top L_e x = \sum_{i,j} L_e(i,j) x_i x_j = x_u^2 + x_v^2 - 2x_u x_v = (x_u - x_v)^2$$

$$x^\top L_G x = x^\top \left(\sum_e L_e \right) x = \sum_e x^\top L_e x = \sum_{e=(u,v)} (x_u - x_v)^2 \leq \sum_e 2(x_u^2 + x_v^2) = 2d \left(\sum_{u \in V} x_u^2 \right)$$

 $\lambda_n = 2d$

even cycles

Conclusion: The condition $\lambda_n = 2d$ implies that G has a bipartite component.

Corollary

If $\lambda_2 \neq 0$ and $\lambda_n = 2d \Leftrightarrow G$ is bipartite.Here, $\lambda_2 \neq 0$ implies that the graph is connected (i.e., has only one connected component).

20. Max Cut & Conductance

- 在图 G 中, 将顶点集合 V 划分为两个部分 S 和 $\bar{S} = V \setminus S$ (即 S 的补集), 我们关心两个集合之间的“边的流通情况”。
- 导通性 (Conductance) 是一种衡量图划分“稀疏程度”的指标, 它反映了划分后, 跨越 S 和 \bar{S} 的边占集合 S 的边总量的比例。

公式定义:

$$\Phi(S) = \frac{E(S, \bar{S})}{\text{Vol}(S)} = \frac{E(S, \bar{S})}{d|S|}$$

其中:

- $\Phi(S)$: 表示集合 S 的导通性。
- $E(S, \bar{S})$: 跨越 S 和 \bar{S} 的边数。
- $\text{Vol}(S) = d|S|$: 集合 S 的总边数 (注意这里假设 G 是 d -正则图, 节点度数固定为 d)。

Let $\lambda_2(G)$ be the second smallest eigenvalue of L_G .

Theorem:

$$\frac{\lambda_2(G)}{d} \leq 2\Phi(G) \leq O\left(\sqrt{\frac{\lambda_2(G)}{d}}\right)$$

$0 < \frac{\lambda_2(G)}{d} < 2$. Since $\lambda_2(G)$ can be calculated, an approximation of $\Phi(G)$ can be understood.

这说明:

- 下界: 导通性 $\Phi(G)$ 的最小值至少和 $\frac{\lambda_2(G)}{d}$ 成正比。
- 上界: 导通性 $\Phi(G)$ 的最小值最多和 $O\left(\sqrt{\frac{\lambda_2(G)}{d}}\right)$ 成正比。



3. Relaxed Goal (松弛目标)

由于精确求解 $\Phi(G)$ 很困难, 松弛目标是找到集合 S , 使得:

$$\Phi(S) \leq 1.01\Phi(G)$$

即, 找到一个“近似解”, 其导通性最多比最优解高出 1%。

近似算法:

- ARV 算法 (Arora-Rao-Vazirani) :

- 输出集合 S , 满足:

$$\Phi(S) = O(\sqrt{\log n})\Phi(G)$$

- 当 $\Phi(G) < \log n$ 时, 该算法表现较好。

- Cheeger 不等式算法:

- 输出集合 S , 满足:

$$\Phi(S) = O(\sqrt{\Phi(G)})$$

- 当 $\Phi(G) > \log n$ 时, 该算法效果较优。

给定一个 d -正则图 $G(V, E)$, 目标是找到一个顶点集 S , 使得:

- $|S| \leq \frac{n}{2}$, 即集合 S 的大小不超过总顶点数的一半;
- 最小化一个指标 $\Phi(S)$, 定义为:



$$\Phi(S) = \frac{\text{穿过切割的边的数量}}{\text{集合 } S \text{ 的大小 } |S|}$$

sparsest cut : $\lambda_2 \leq 2\Phi(G) = O(\Phi(G))$

21. convex set:

1. 关于凸集 (Convex Set) 的定义

一个集合 $A \subseteq \mathbb{R}^n$ 被称为凸集, 当且仅当对于集合中的任意两个点 $x, y \in A$, 其连接线上的任意一点 (即 $\lambda x + (1 - \lambda)y$ 对于 $\lambda \in [0, 1]$) 也属于该集合 A 。公式定义为:

$$x, y \in A \implies \lambda x + (1 - \lambda)y \in A \quad (\lambda \in [0, 1])$$

第一步: 证明 Δ 是凸集

集合 Δ 是所有 $\{z : z = \sum_{i=1}^m \lambda_i x_i\}$ 形成的凸包, 满足权重 $\lambda_i \geq 0$ 且 $\sum_{i=1}^m \lambda_i = 1$ 。

- 设 $z_1, z_2 \in \Delta$, 则存在权重 $\{\lambda_i^1\}$ 和 $\{\lambda_i^2\}$, 使得:

$$z_1 = \sum_{i=1}^m \lambda_i^1 x_i, \quad z_2 = \sum_{i=1}^m \lambda_i^2 x_i.$$

- 对于任意 $\theta \in [0, 1]$, 定义 $z = \theta z_1 + (1 - \theta)z_2$, 则:

$$z = \theta \sum_{i=1}^m \lambda_i^1 x_i + (1 - \theta) \sum_{i=1}^m \lambda_i^2 x_i.$$

- 将权重合并为 $\lambda_i = \theta \lambda_i^1 + (1 - \theta) \lambda_i^2$, 有:

$$z = \sum_{i=1}^m \lambda_i x_i.$$

- 检查权重是否满足条件:

- 非负性: $\lambda_i = \theta \lambda_i^1 + (1 - \theta) \lambda_i^2 \geq 0$;
- 归一性: $\sum_{i=1}^m \lambda_i = \theta \sum_{i=1}^m \lambda_i^1 + (1 - \theta) \sum_{i=1}^m \lambda_i^2 = 1$ 。

因此, Δ 是凸集。

假设:

- x^* 和 y^* 是线性规划的可行解。
- $\lambda x^* + (1 - \lambda)y^*$ 是它们之间的线性组合, 且 $\lambda \in [0, 1]$ 。

证明: $\lambda x^* + (1 - \lambda)y^*$ 也是可行解。

计算:

$$a^{(1)} \cdot (\lambda x^* + (1 - \lambda)y^*) = \lambda(a^{(1)} \cdot x^*) + (1 - \lambda)(a^{(1)} \cdot y^*)$$

由于 x^* 和 y^* 是可行解, 满足 $a^{(1)} \cdot x^* \geq b_1$ 和 $a^{(1)} \cdot y^* \geq b_1$, 因此:

$$\lambda a^{(1)} \cdot x^* + (1 - \lambda)a^{(1)} \cdot y^* \geq \lambda b_1 + (1 - \lambda)b_1 = b_1$$

类似的, 所有约束 $a^{(i)} \cdot x \geq b_i$ 对 $i = 1, 2, \dots, m$ 都成立。因此, $\lambda x^* + (1 - \lambda)y^*$ 是可行解。

4. 顶点解 (Vertex Solution)

定义: 在凸集中, 一个点 $x \in C$ 是顶点 (vertex), 如果对于 $\lambda \in [0, 1]$, $x = \lambda y + (1 - \lambda)z$ (且 $y, z \in C$) 时, 总有 $y = x$ 或 $z = x$ 。

5. 线性规划的最优解出现在顶点

结论: 对于线性规划问题 $\min c \cdot x$, 最优解要么出现在无界区域, 要么出现在顶点。

证明要点:

- 如果最优解不是顶点, 则可以表示为两个不同点 y^* 和 z^* 的线性组合:

$$x^* = \lambda y^* + (1 - \lambda)z^*, \quad \lambda \in [0, 1]$$

$$c \cdot x^* = \lambda c \cdot y^* + (1 - \lambda)c \cdot z^*.$$

- 如果 x^* 是最优解, y^* 或 z^* 至少有一个达到相同的最优值。因此, 问题可以简化为检查凸集的顶点。

22. Convex function:

• 凸函数:

函数 f 是凸函数, 当且仅当对于任意 $x, y \in \text{dom}(f)$ 和 $\theta \in [0, 1]$, 有

$$f(\theta x + (1 - \theta)y) \leq \theta f(x) + (1 - \theta)f(y).$$

凸函数的直观解释是, 其图像不会在连接任意两点的直线上方。

Definition of Convexity for a Function: A function $g(x)$ is convex if, for any $x_1, x_2 \in \mathbb{R}^n$ and $\lambda \in [0, 1]$,

$$g(\lambda x_1 + (1 - \lambda)x_2) \leq \lambda g(x_1) + (1 - \lambda)g(x_2).$$

23. Maximum Flow & SVM

考虑一个有向图 $G = (V, E)$, 其中每条边 $e \in E$ 都有一个容量 $c_e \geq 0$, 表示这条边可以通过的最大流量。此外, 指定两个顶点: 源点 s 和汇点 t 。

目标是从源点 s 到汇点 t 发送最大流量, 同时满足容量约束和流守恒约束。

约束条件

- 1. 非负性约束: 所有边上的流量 $x_e \geq 0$, 即流量不能为负。
- 2. 容量约束: $x_e \leq c_e$, 即每条边上的流量不能超过其容量。
- 3. 流守恒约束: 对于除源点 s 和汇点 t 外的所有顶点 v , 进入 v 的流量等于离开 v 的流量。即:

$$\sum_{e=(u,v)} x_e = \sum_{e=(v,w)} x_e.$$

目标

在满足上述约束的前提下, 最大化从源点到汇点的总流量:

$$\max \sum_{e \in E} x_e,$$

SVM 是一种用于分类和回归分析的机器学习算法。这里简要提到 SVM 的两个模型。

特征和标签

- 特征 (Attributes): 每个样本有 n 个特征, 表示为: $x^{(1)}, x^{(2)}, \dots, x^{(m)} \in \mathbb{R}^n$. 例如: 房子的面积、卧室数量等。
- 标签 (Labels): 对应的目标值或类别为: $a^{(1)}, a^{(2)}, \dots, a^{(m)} \in \mathbb{R}$.

模型 0

- 假设: $a^{(i)} = w \cdot x^{(i)}$, 其中 w 是未知向量 (分类模型中的权重向量)。
- 如果 w 存在, 则可以通过高斯消元法 (Gaussian Elimination) 来求解。

模型 1

将特征表示为一个矩阵:



优化目标

我们需要评估向量 $a \in \mathbb{R}^m$ 与由 $b^{(1)}, b^{(2)}, \dots, b^{(m)}$ 张成的子空间之间的接近程度。

目标是最小化:

$$\|a - \Sigma w b^{(i)}\|_2,$$

即向量 a 到张成子空间的 L_2 范数距离。

进一步扩展到误差建模

为了引入误差的约束, 目标误差被定义为 ξ , 并约束每个样本的误差满足:

$$\|a^{(i)} - w \cdot x^{(i)}\| \leq \xi \cdot a^{(i)} \quad \text{for } i \leq m.$$

这意味着我们希望每个数据点 $a^{(i)}$ 的预测值 $w \cdot x^{(i)}$ 尽可能接近真实值, 同时限制误差的比例不超过 $\xi \cdot a^{(i)}$ 。

线性化约束

通过分解, 可以将误差约束改写为线性约束形式:

$$-\xi^{(i)} \cdot a^{(i)} \leq a^{(i)} - w \cdot x^{(i)} \leq \xi^{(i)} \cdot a^{(i)},$$

并以最小化 ξ 作为目标。

24. Approximation Algorithm & Vertex Cover

对于难以精确解决的优化问题 (如 NP-hard 问题), 使用近似算法是一个常见策略。目标是找到接近最优解的可行解。

- 定义: 给定一个最小化问题 C , 算法 A 被称为 α -近似算法, 如果对于任何实例 I , 其输出满足: $A(I) \leq \alpha \cdot OPT(I)$ 其中:
 - $OPT(I)$ 是最优解的值,
 - $\alpha \geq 1$ 是近似比, 表示算法结果与最优解的偏差。

给定一个无向图, 目标是找到一个顶点的子集, 使得图中的每条边至少有一个端点在该子集中。

1. 问题定义

- 顶点覆盖问题: 目标是找到一个最小顶点集, 使得图中每条边的至少一个端点在该集合中。
- 目标: 设计一个 2-近似算法, 即找到的顶点覆盖的大小 S 满足:

$$|S| \leq 2 \cdot OPT$$

其中 OPT 是问题的最优解。

2. 原始问题的线性规划形式 (OPT*)

- 变量 x_u : 表示顶点 u 是否属于顶点覆盖, 取值为 0 或 1。
- 约束条件:
 - $x_u + x_v \geq 1$: 每条边 (u, v) 至少有一个端点被覆盖。
- 目标函数:

$$\min \sum_{u \in V} x_u \quad \text{4. 推导不等式}$$

将上述性质应用到 $|S|$ 的表达式中, 我们可以写成:

即最小化顶点覆盖的大小。

将每一项 $\frac{1(u \in S)}{x_u}$ 的值替换为 ≤ 2 , 得到:

$$|S| \leq \sum_{u \in V} 2 \cdot x_u.$$

3. 松弛后的线性规划 (LP**)

因此:

通过将变量 $x_u \in \{0, 1\}$ 松弛为 $0 \leq x_u \leq 1$, 问题变为:

$$\min \sum_{u \in V} x_u$$

同时满足:

- $x_u + x_v \geq 1$: 每条边至少覆盖一个端点。

5. 结论

由于 $\sum_{u \in V} x_u$ 是松弛线性规划问题 (***) 的最优目标值 (即 OPT of the LP), 我们最终得到:

$$|S| \leq 2 \cdot (\text{OPT of the LP}),$$

从而证明了 Claim 2.

根据 Claim 1, 我们有:

$|S| \leq 2 \cdot (\text{OPT of the LP})$

根据 Claim 2, 我们有:

$|S| \leq 2 \cdot (\text{OPT of the LP})$

其中 x_u 是松弛线性规划的最优解。

2. 分析 $|S|$ 和 $\sum_{u \in V} x_u$

根据定义, $|S|$ 可以写成:

$$|S| = \sum_{u \in S} 1(u \in S),$$

其中 $1(u \in S)$ 是一个指示函数, 当 $u \in S$ 时等于 1, 否则等于 0。

3. 取整的关键性质

当 $u \in S$ 时, 根据规则 $x_u \geq 0.5$ 。因此, 每个 $u \in S$, 我们有:

$$\frac{1(u \in S)}{x_u} \leq \frac{1}{0.5} = 2.$$

k -clique:

Best vertex cover: $k-1$

Best fractional solution: $\frac{k}{2}$

25. Set Cover

• 输入:

- 一个全集 $U = \{a_1, a_2, \dots, a_n\}$, 包含 n 个元素。
- 一组子集 $S_1, S_2, \dots, S_m \subseteq U$ 。
- 子集的并集必须覆盖全集: $\bigcup_{i \in [m]} S_i = U$ 。
- 目标: 找到一个最小的子集索引集合 $I \subseteq [m]$, 使得:

$$\bigcup_{i \in I} S_i = U$$

即, 选择尽可能少的子集覆盖全集。

• 决策变量:

- $x_j \in \{0, 1\}, \forall 1 \leq j \leq m$
- $x_j = 1$ 表示选择了集合 S_j ;
- $x_j = 0$ 表示未选择集合 S_j 。

2. 约束条件:

- $\forall i \in [n], \sum_{j: i \in S_j} x_j \geq 1$
- 每个元素 i 必须被至少一个被选择的集合覆盖。

3. 目标函数:

- 最小化 $\sum_{j=1}^m x_j$
- 最小化选择集合的数量。

23.2.3 线性规划松弛 (LP Relaxation)

为了求解集合覆盖问题, 可以将整数线性规划 (ILP) 转化为线性规划 (LP), 这是通过松弛约束来实现的。我们将该线性规划表示为 (**).

表述:

1. 决策变量松弛:

- 在 ILP 中, $x_j \in \{0, 1\}$, 表示集合 S_j 是否被选中;
- 在 LP 中, 松弛为 $0 \leq x_j \leq 1$, 允许 x_j 是一个连续值。

2. 约束条件:

- $\forall i \in [n], \sum_{j: i \in S_j} x_j \geq 1$
- 与 ILP 相同, 每个元素 i 必须被至少一个集合覆盖。

3. 目标函数:

- 最小化 $\sum_{j=1}^m x_j$
- 尽可能减少选中的集合数量。

$$\forall j \in [n], \sum_{i: j \in S_i} x_i \geq 1.$$

这个约束条件的含义是什么?

表示形式:

- 这个不等式对全集中的每个元素 $j \in U$ 都要成立。
- $i: j \in S_i$ 表示所有包含元素 j 的子集 S_i 。
- x_i 是指是否选择了子集 S_i :
- 如果 $x_i = 1$, 表示子集 S_i 被选中;
- 如果 $x_i = 0$, 表示子集 S_i 没有被选中。

解释: 这个约束的意思是: 全集 U 中的每个元素 j 必须至少被一个被选中的子集覆盖。

定理 23.1: 存在一个 $O(\log n)$ 逼近算法来解决集合覆盖问题, 这种逼近可以改进为 $\ln n + \Theta(1)$

Claim: Objective value of (**) \leq objective value of (*). Since (**) is a relaxation of (*), any solution of (*) satisfies the requirements of (**), which means that the objective value of (**) is more optimized than (*), thus smaller in our case.

26. Randomized Approximation

Fact: $1 - x \leq e^{-x}$ for $x \in [0, 1]$. This will be used in later steps.

1. 随机选择集合:

- 对于每个集合 S_j , 以概率 x_j 将其加入集合 C (这里的 x_j 是从线性规划 (LP) 解中得到的)。

2. 未被覆盖的概率:

- 一个元素 i 未被覆盖的概率为:

$$\prod_{j: i \in S_j} (1 - x_j)$$

- 基于 $1 - x \leq e^{-x}$ 的不等式, 这个概率可以近似为:

$$\prod_{j: i \in S_j} e^{-x_j} = e^{-\sum_{j: i \in S_j} x_j} \leq \frac{1}{e}$$

- 这表示每个元素 i 被漏掉的概率最多是 $\frac{1}{e}$ 。

Let the number of sets added to C in round i be y_i . The expectation of y_i is:

$$\begin{aligned} \mathbb{E}[y_i] &= \sum_{j=1}^m \mathbb{E}[\mathbb{1}[S_j \text{ was added to } C]] \\ &= \sum_{j=1}^m x_j \\ &= L \end{aligned}$$

Since $|C| \leq y_1 + \dots + y_T$, $\mathbb{E}[|C|] \leq \mathbb{E}[y_1] + \dots + \mathbb{E}[y_T] = TL$.

第一步: 用 Markov 不等式限制集合大小

Markov 不等式告诉我们, 对于非负随机变量 X ,

Suppose we set $T = \ln n + 10$, then the probability that i is not covered in T rounds $\leq e^{-(\ln n + 10)} \leq \frac{e^{-10}}{n}$. As a result, the probability that $\exists i \in [n]$ not covered in T rounds $\leq n \cdot \frac{e^{-10}}{n} = e^{-10}$ (by union bound) \Rightarrow w.p. $1 - e^{-10}$, every element i is covered.

将其应用到集合大小 $|C|$ 上:

By Markov's Inequality, w.p. $\frac{9}{10}$:

1. 随机变量:

- $X = |C|$, 表示集合 C 的实际大小。

$$|C| \leq 10 \cdot T \cdot L$$

$$= O(L \log n)$$

2. 期望值:

- $\mathbb{E}[|C|] = T \cdot L$.

\therefore w.p. $1 - e^{-10} - \frac{1}{10}$, both events happen. The probability evaluates to $\geq 89.9\%$.

3. 阀值:

- 选择 $a = 10 \cdot T \cdot L$, 即我们希望控制集合大小不会超过 $10 \cdot T \cdot L$.



4. 结果:

- 根据 Markov 不等式:

$$\Pr(|C| \geq 10 \cdot T \cdot L) \leq \frac{\mathbb{E}[|C|]}{10 \cdot T \cdot L} = \frac{T \cdot L}{10 \cdot T \cdot L} = \frac{1}{10}.$$

- 解释: 集合 C 的大小超过 $10 \cdot T \cdot L$ 的概率最多是 $\frac{1}{10}$. 换句话说, 有 90% 的概率, 集合 $|C| \leq 10 \cdot T \cdot L$.

8. Markov's inequality

Suppose Z is a non-negative random variable, then $\forall t \geq 1$, $\Pr[Z \geq t \cdot \mathbb{E}[Z]] \leq \frac{1}{t}$

HW 3 :

1. [3 + 3 points] (i) Suppose A is a symmetric matrix. Then prove that all the eigenvalues of A are non-negative if and only if $x^T A x \geq 0$ for every $x \in \mathbb{R}^n$. (Remark: such a matrix A is called a psd matrix).

(ii) Suppose $A \in \mathbb{R}^{n \times n}$ is a psd matrix. Prove that for any matrix $B \in \mathbb{R}^{m \times n}$, BAB^T is also psd.

2. [5 points] Suppose A is a square matrix of size $n \times n$ (not necessarily symmetric). Let the SVD of A be given by $\sum_{i=1}^n \sigma_i u_i v_i^T$ where $\sigma_i \neq 0$ (for all i). Prove the the inverse of A is given by $\sum_{i=1}^n \sigma_i^{-1} v_i u_i^T$. (Recall that the inverse of a square matrix A is the unique matrix B such that $BA = AB = I$).

3. [3 points] (a) Suppose A is symmetric matrix. We know from standard linear algebra that $\text{Tr}(A) = \sum_{i=1}^n \lambda_i$ where $\lambda_1, \dots, \lambda_n$ are the eigenvalues of A . Prove that $\text{Tr}(A^k) = \sum_{i=1}^n \lambda_i^k + \dots + \lambda_n^k$.

(b) [5 points] Consider a random matrix $A \in \mathbb{R}^n$ defined as follows: entry $A(i, j)$ (where $i \leq j$) is set to ± 1 with probability $1/2$. If $i > j$, then $A(i, j)$ is set to be equal to $A(j, i)$. Compute $\mathbb{E}[\text{Tr}(A^4)]$ and use that to prove that $\max_i |\lambda_i| = O(n^{3/4})$ with probability 0.99.

Hint: For part (b), write the expression for $\text{Tr}(A^4)$ in terms of the entries of A and then use simple linearity of expectation.

1 Question 1

1. Let's first assume all the eigenvalues of A are non-negative. Because we know A is symmetric, we know it can be diagonalized to $A = U\Lambda U^\top$ where U is an orthogonal matrix and Λ is a diagonal matrix which contains eigenvalues $\lambda_i \geq 0$. We also know $U^\top U = I$.

Then, for any vector $x \in \mathbb{R}^n$, we have:

$$x^T A x = x^T U \Lambda U^\top x = (U^\top x)^\top \Lambda (U^\top x)$$

We set $y = Q^\top x$, and the equation would become $(U^\top x)^\top \Lambda (U^\top x) = y^\top \Lambda y$

Because we know Λ is a diagonal matrix which contains eigenvalues $\lambda_i \geq 0$, we know all of its entries are non-negative. Thus, we can deduce:

$$\begin{aligned} x^T A x &= y^\top \Lambda y = \sum_{i=1}^n \lambda_i y_i^2 \geq 0 \\ x^T A x &\geq 0 \end{aligned}$$

Proof by contradiction: if A has a negative eigenvalue $\lambda_x < 0$, and its eigenvector is $v_x \neq 0$, we have:

$$v_x^\top A v_x = v_x^\top (\lambda_x v_x) = \lambda_x v_x^\top v_x = \lambda_x \|v_x\|^2 < 0$$

This contradicts with the conclusion $v^\top A v \geq 0$, so all the eigenvalues of A must be non-negative.

2. Suppose we have a random vector $x \in \mathbb{R}^m$, we want to put it in the matrix BAB^T :

$$x^\top (BAB^T)x = (B^\top x)^\top A (B^\top x)$$

Suppose we have another vector $y = B^\top x \in \mathbb{R}^n$, because we know A is psd, $y^\top A y \geq 0$. Thus, we have:

$$\begin{aligned} x^\top (BAB^T)x &= y^\top A y \geq 0 \\ x^\top (BAB^T)x &\geq 0 \end{aligned}$$

This holds for all $x \in \mathbb{R}^m$. Therefore, BAB^T is psd.

3. We first deduce the expression of $\text{Tr}(A^4)$ in terms of the entries of A :

$$\text{Tr}(A^4) = \sum_{i=1}^n \sum_{j=1}^n \sum_{l=1}^n \sum_{k=1}^n A_{ij} A_{jk} A_{kl} A_{li}$$

The index is a close loop, since the trace is the sum of the diagonal position.

Based on the linearity of expectation:

$$\mathbb{E}[\text{Tr}(A^4)] = \sum_{i=1}^n \sum_{j=1}^n \sum_{k=1}^n \sum_{l=1}^n \mathbb{E}[A_{ij} A_{jk} A_{kl} A_{li}]$$

Note that A is symmetric and the number on each entry is randomly chosen and has an expectation of 0. Therefore the expectation of each entry is non-zero when every entry appears an even number of times.

There are 3 scenarios:

1. all the 4 indices are the same, i.e $i = j = k = l$. The expectation of this term is:

$$\sum_{i=1}^n \mathbb{E}[A_{ii}^4] = n$$

2. 3 indices are the same, e.g. $j = k = l$. This pattern appears 4 times. The expectation of this term is:

$$4 \sum_{i=1}^n \sum_{j=1, j \neq i}^n \mathbb{E}[A_{jj}^2 A_{ij}^2] = 4n^2 - 4n$$

3. 2 indices are the same, i.e. $i = k, j = l$ and $i = j, k = l$ and $i = l, j = k$. This pattern appears 3 times. The expectation of this term is:

$$\sum_{i=1}^n \sum_{j=1, j \neq i}^n \mathbb{E}[A_{ij}^4] + 2 \sum_{i=1}^n \sum_{j=1, j \neq i}^n \mathbb{E}[A_{jj}^2 A_{ij}^2] = 3n^2 - 3n$$

Therefore the explicit expression of expectation is:

$$\mathbb{E}[\text{Tr}(A^4)] = 7n^2 - 6n$$

By Markov's inequality, let $Z = \text{Tr}(A^4)$, $t = \frac{n^4}{7n^2 - 6n}$:

$$\begin{aligned} \Pr[Z \geq t\mathbb{E}[Z]] &\leq \frac{1}{t} \\ \Pr[Z \geq n^4] &\leq \frac{7n - 6}{n^3} \end{aligned}$$

Noted that:

$$Z = \text{Tr}(A^4) = \sum_i^n \lambda_i^4 \leq n \cdot \max_i |\lambda_i|^4$$

$\max_i |\lambda_i|^4$ is also a random variable, so we can determine its inequality by the above Markov's inequality:

$$\begin{aligned} \Pr[n \cdot \max_i |\lambda_i|^4 \geq n^4] &\leq \frac{7n - 6}{n^3} \\ \Pr[\max_i |\lambda_i| \geq n^{3/4}] &\leq \frac{7n - 6}{n^3} \end{aligned}$$

When n is large enough, without the loss of generality, let $n = 100$, $\Pr[\max_i |\lambda_i| \geq n^{3/4}] \leq 0.0007$

Therefore $\max_i |\lambda_i| = O(n^{3/4})$ with probability at least 0.99.

HW4

1. [5 points] Let G be a d -regular graph and let L_G be its Laplacian. Let the eigenvalues of L_G be $\lambda_1 \leq \dots \leq \lambda_n$. Prove that $\lambda_k = 0$ iff the Graph G has at least k connected components.

2. (i) [3 points] A matrix $P \in \mathbb{R}^{n \times n}$ is said to be a permutation matrix if there is a permutation $\sigma : [n] \rightarrow [n]$ such that $P(i, j) = 1$ if and only if $\sigma(i) = j$. Prove that if $Av = \lambda v$ for some vector v , then, Pv is an eigenvector of PAP^{-1} with eigenvalue λ .

(b) [3 points] For a permutation $\sigma : [n] \rightarrow [n]$, let P be the permutation matrix. Then, show that (i, j) th entry of PAP^{-1} is $A_{\sigma(i), \sigma(j)}$.

3. [4 points] (a) Suppose $A \in \mathbb{R}^{m \times n}$. Let the SVD of A be $\sum_i \sigma_i u_i v_i^T$. Prove that

$$\max_{x \in \mathbb{R}^m, \|x\|_2=1, y \in \mathbb{R}^n, \|y\|_2=1} x^T A y = \max_i \sigma_i.$$

[5 points] (b) For a rectangular matrix A , we often use $\|A\|_2$ to denote the maximum singular value of A . Prove the following inequalities:

$$\|A + B\|_2 \leq \|A\|_2 + \|B\|_2;$$

$$\|A \cdot B\|_2 \leq \|A\|_2 \cdot \|B\|_2.$$

4. [5 points] Suppose you have a vector $v \in \mathbb{R}^n$ such that $\|v\|_2 = 1$. Consider another vector u which encodes a set $S \subseteq [n]$ as follows: If $i \in S$, $u_i = 1/\sqrt{n}$. If $i \notin S$, $u_i = -1/\sqrt{n}$.

You're given v but not u . Furthermore, you're told that $\|v - u\|_2 \leq \epsilon$. Let us define $S' = \{i : v_i \geq 0\}$. Prove that $|S \Delta S'| = O(\epsilon^2 n)$.

1 Question 1

1. Let c be the number of connected components in G . Since we know the multiplicity of the eigenvalue zero of the Laplacian matrix L_G equals the number of connected components in G , we can deduce that the multiplicity of the eigenvalue zero is c . This implies the smallest c eigenvalues are all zero:

$$\lambda_1 = \lambda_2 = \dots = \lambda_c = 0$$

It obvious that $c \geq k$, so $\lambda_k = 0$. Therefore, if G has at least k connected components, $\lambda_k = 0$.

Secondly, let us assume $\lambda_k = 0$, this implies the multiplicity of the zero eigenvalue is at least k . Since we also know the multiplicity of the zero eigenvalue equals the number of connected components, G should have at least k connected components. Therefore, if $\lambda_k = 0$, G should have at least k connected components.

Thus, $\lambda_k = 0$ iff the Graph G has at least k connected components.

2 Question 2

1. Consider the expression $(PAP^{-1})(Pv)$, we first regroup this expression:

$$(PAP^{-1})(Pv) = (PA)(P^{-1}Pv)$$

Notice that $P^{-1}P = I$, where I is the identity matrix:

$$P^{-1}Pv = v$$

Thus, the expression simplifies to:

$$(PAP^{-1})(Pv) = (PA)v = P(Av)$$

Notice that v is the eigenvector of A :

$$Av = \lambda v$$

1

3

Then, we want to compute $x^T A y$.

$$x^T A y = (\sum_i \alpha_i u_i^T) \left(\sum_j \sigma_j u_j v_j^T \right) (\sum_k \beta_k v_k) = \sum_i \sigma_i \alpha_i \beta_i.$$

To maximize $x^T A y$, we need to maximize $\sum_i \sigma_i \alpha_i \beta_i$ under the constraints we mentioned above.

By applying Cauchy-Schwarz inequality ($|\sum_i a_i b_i| \leq (\sum_i a_i^2)^{1/2} (\sum_i b_i^2)^{1/2}$) and set $a_i = \sigma_i^{1/2} \alpha_i$ and $b_i = \sigma_i^{1/2} \beta_i$, we get:

$$\sum_i \sigma_i \alpha_i \beta_i \leq \left(\sum_i \sigma_i \alpha_i^2 \right)^{1/2} \left(\sum_i \sigma_i \beta_i^2 \right)^{1/2}$$

Since σ_i is in decreasing order, $\sigma_1 = \max_i \sigma_i$ because it is the largest. The maximum value is achieved when $\alpha_1 = 1$, $\beta_1 = 1$, and all other α_i , β_i are zero.

Therefore:

$$\max_{\substack{x \in \mathbb{R}^m, \|x\|_2=1 \\ y \in \mathbb{R}^n, \|y\|_2=1}} x^T A y = \sigma_1 = \max_i \sigma_i$$

$$\max_{\substack{x \in \mathbb{R}^m, \|x\|_2=1 \\ y \in \mathbb{R}^n, \|y\|_2=1}} x^T A y = \max_i \sigma_i$$

2. (a) Operator norm is as follows:

$$\|A\|_2 = \max_{\|x\|_2=1} \|Ax\|_2$$

Based on triangle inequality, we can deduce that for any x with $\|x\|_2 = 1$:

$$\|(A + B)x\|_2 \leq \|Ax\|_2 + \|Bx\|_2$$

If we divide both sides by $\|x\|_2$, the equation remains the same as $\|x\|_2 = 1$.

Take the maximum over all x , we get:

$$\|A + B\|_2 = \max_{\|x\|_2=1} \|(A + B)x\|_2 \leq \max_{\|x\|_2=1} (\|Ax\|_2 + \|Bx\|_2) \leq \|A\|_2 + \|B\|_2$$

Therefore:

$$\|A + B\|_2 \leq \|A\|_2 + \|B\|_2$$

(b) We start by recalling the definition of the operator norm for a product of matrices:

$$\|AB\|_2 = \max_{\|x\|_2=1} \|ABx\|_2$$

Using the property of norms, we deduce that:

$$\|ABx\|_2 \leq \|A\|_2 \|Bx\|_2$$

3 Question 3

1. We know $\{u_i\}$ and $\{v_i\}$ form orthonormal bases, so unit vectors x and y can be expressed as follows:

$$x = \sum_i \alpha_i u_i, \quad y = \sum_i \beta_i v_i$$

We also know that $\sum_i \alpha_i^2 = 1$ and $\sum_i \beta_i^2 = 1$.

2. We know $\{u_i\}$ and $\{v_i\}$ form orthonormal bases, so unit vectors x and y can be expressed as follows:

$$x = \sum_i \alpha_i u_i, \quad y = \sum_i \beta_i v_i$$

We also know that $\sum_i \alpha_i^2 = 1$ and $\sum_i \beta_i^2 = 1$.

Next, we bound $\|Bx\|_2$ by applying the operator norm of B . We also know $\|x\|_2 = 1$:

$$\|Bx\|_2 \leq \|B\|_2 \|x\|_2 = \|B\|_2$$

Combine these inequalities, we get this:

$$\|ABx\|_2 \leq \|A\|_2 \|B\|_2$$

Finally, taking the maximum over all x with $\|x\|_2 = 1$, we deduce:

$$\|AB\|_2 = \max_{\|x\|_2=1} \|ABx\|_2 \leq \|A\|_2 \|B\|_2$$

Thus,

$$\|AB\|_2 \leq \|A\|_2 \cdot \|B\|_2$$

4 Question 4

- Given that $\|v - u\|_2 \leq \epsilon$. This means:

$$\sum_{i=1}^n (v_i - u_i)^2 \leq \epsilon^2$$

$|S \Delta S'|$ denote the size of the symmetric difference between sets S and S' , which is:

$$|S \Delta S'| = |(S \setminus S') \cup (S' \setminus S)|$$

Notice that $S = \{i : u_i \geq 0\}$, $S' = \{i : v_i \geq 0\}$. By definition, the size of the symmetric difference increases when:

$$u_i \geq 0, v_i < 0 \text{ or } u_i < 0, v_i \geq 0$$

- when $u_i \geq 0, v_i < 0$ then $u_i = \frac{1}{\sqrt{n}}, v_i < 0$. The squared difference is:

$$(v_i - u_i)^2 \geq (\frac{1}{\sqrt{n}})^2 = \frac{1}{n}$$

- when $u_i < 0, v_i \geq 0$ then $u_i = -\frac{1}{\sqrt{n}}, v_i \geq 0$. The squared difference is:

$$(v_i - u_i)^2 \geq (\frac{1}{\sqrt{n}})^2 = \frac{1}{n}$$

Let d be the size of the symmetric difference, i.e. $d = |S \Delta S'|$, then:

$$d \cdot \frac{1}{n} \leq \sum_{i \in S \Delta S'} (v_i - u_i)^2 \leq \sum_{i=1}^n (v_i - u_i)^2 \leq \epsilon^2$$

Thus:

$$d \leq \epsilon^2 n$$

This proves that $|S \Delta S'| = O(\epsilon^2 n)$

HW5:

- You already know what it means for a set D to be convex. A function $f : D \rightarrow \mathbb{R}$ is said to be convex if for every $x, y \in D$ and $\lambda \in [0, 1]$,

$$f(\lambda x + (1 - \lambda)y) \leq \lambda f(x) + (1 - \lambda)f(y).$$

- [3 points] For $t \in \mathbb{R}$, prove that the set $D_t = \{x : x \in D \text{ and } f(x) \leq t\}$ is a convex set.

- [3 points] Let A be a positive semidefinite matrix. Then, for any $\theta \geq 0$, prove that $Z_{A,\theta} = \{x \in \mathbb{R}^n : x^T Ax \leq \theta\}$ is a convex set.

1 Question 1

- We want to show D_t is convex, so based on the definition of convex set, we need to prove: for any $m, n \in D_t$ and $\lambda \in [0, 1]$, point $z = \lambda m + (1 - \lambda)n$ also belongs to D_t .

We know $m, n \in D_t$, and for any $x \in D_t$, $f(x) \leq t$, so we can deduce: $f(m) \leq t$, and $f(n) \leq t$.

We know f is a convex function, so based on the convexity of the function, we have:

$$f(z) = f(\lambda m + (1 - \lambda)n) \leq \lambda f(m) + (1 - \lambda)f(n) \leq \lambda t + (1 - \lambda)t = t$$

So,

$$f(z) \leq t$$

This implies:

$$z \in D_t$$

Thus, D_t is indeed a convex set.

- We first want to prove function $f(x) = x^T Ax$ is convex. That's to say, we want to prove:

For any $x, y \in \mathbb{R}^n$ and $\lambda \in [0, 1]$:

$$f(\lambda x + (1 - \lambda)y) \leq \lambda f(x) + (1 - \lambda)f(y)$$

$$f(\lambda x + (1 - \lambda)y) = (\lambda x + (1 - \lambda)y)^T A (\lambda x + (1 - \lambda)y) = \lambda^2 x^T Ax + 2\lambda(1 - \lambda)x^T Ay + (1 - \lambda)^2 y^T Ay$$

Then, we compute $\lambda f(x) + (1 - \lambda)f(y)$:

$$\lambda f(x) + (1 - \lambda)f(y) = \lambda x^T Ax + (1 - \lambda)y^T Ay$$

Now, we take the difference of the two (which is $f(\lambda x + (1 - \lambda)y) - [\lambda f(x) + (1 - \lambda)f(y)]$):

$$\begin{aligned} \text{difference} &= [\lambda^2 x^T Ax + 2\lambda(1 - \lambda)x^T Ay + (1 - \lambda)^2 y^T Ay] - [\lambda x^T Ax + (1 - \lambda)y^T Ay] \\ &= \lambda^2 x^T Ax - \lambda x^T Ax + 2\lambda(1 - \lambda)x^T Ay - (1 - \lambda)y^T Ay \\ &= -\lambda(1 - \lambda)x^T Ax + 2\lambda(1 - \lambda)x^T Ay - \lambda(1 - \lambda)y^T Ay \\ &= \lambda(1 - \lambda) [-x^T Ax + 2x^T Ay - y^T Ay] \end{aligned}$$

We notice:

$$\text{difference} = \lambda(1 - \lambda) [-x^T Ax + 2x^T Ay - y^T Ay] = \lambda(1 - \lambda) [-(x - y)^T A(x - y)]$$

Because we know A is psd and symmetric, $(x - y)^T A(x - y) \geq 0$. Thus:

$$\text{difference} \leq 0$$

Thus:

$$f(\lambda x + (1 - \lambda)y) \leq \lambda f(x) + (1 - \lambda)f(y).$$

Therefore, $f(x) = x^T Ax$ is convex.

Secondly, we want to prove $Z_{A,\theta}$ is a convex set:

For $m, n \in Z_{A,\theta}$, we have $m^T Am \leq \theta$ and $n^T An \leq \theta$.

For $\lambda \in [0, 1]$, we have:

$$(\lambda m + (1 - \lambda)n)^T A (\lambda m + (1 - \lambda)n) \leq \lambda m^T Am + (1 - \lambda)n^T An \leq \lambda\theta + (1 - \lambda)\theta = \theta$$

This implies:

$$\lambda m + (1 - \lambda)n \in Z_{A,\theta}$$

Thus, $Z_{A,\theta}$ is a convex set.